



LLM4Gov: Governança e Ética como Agentes de Decisão no Setor Público

Prof. Dr. Jorge Valverde-Rebaza

Outubro, 2025



Introdução

Momento da Governança em LLMs



Exemplo: domínio jurídico



**Procuradoria-Geral
da Fazenda Nacional**



Development of Large Language Models for Applications in the Legal Domain

Grant number: 23/10100-4

Grouped support types: Research Grants - Research in Public Policies

Duration: May 01, 2024 - April 30, 2028

Field of knowledge: Physical Sciences and Mathematics - Computer Science - Computing Methodologies and Techniques

Exemplo: fiscalização



SEFAZ RS
SECRETARIA DA FAZENDA




Buscando economia em licitações, Sefaz fecha parceria com a USP para precificação de produtos com base em notas fiscais

GERAL

RECEITA ESTADUAL

TESOURO DO ESTADO



Termo de cooperação técnica foi firmado durante o evento on-line PIT Talks - Foto: Reprodução

[Download HD](#)

Projeto, que já garantiu R\$ 700 milhões economizados, passa a utilizar recursos de inteligência artificial, o que é considerado um salto tecnológico pela secretaria

A Secretaria da Fazenda (Sefaz), por meio do Tesouro do Estado, celebrou um termo de cooperação técnica com o Centro de Inteligência Artificial da Universidade de São Paulo (USP) para o projeto de precificação com base na Nota Fiscal Eletrônica (NF-e). A

CIAM CENTRO DE
INTELIGÊNCIA ARTIFICIAL E
APRENDIZADO DE MÁQUINA

Exemplo: mapeamento e monitoramento



Ministério da Educação



Entrar com gov.br

≡ CAPES



Observatório da Agenda Nacional de Formação de Pessoal Nível Superior

Publicado em 31/12/2024 10h58 | Atualizado em 08/01/2025 11h41

Compartilhe: [f](#) [in](#) [whatsapp](#) [link](#) [hand](#)


Trata-se de Termo de Execução Descentralizada (TED), entre a CAPES e a Universidade Federal do Mato Grosso do Sul (UFMS), para desenvolvimento do Observatório da Agenda Nacional de Formação de Pessoal de Nível Superior.

A iniciativa visa fortalecer a governança do Sistema Nacional de Pós-Graduação (SNPG) a partir de duas estratégias principais, a saber:

I. a formalização da Agenda Nacional de temas estratégicos prioritários declarados pelas 27 Unidades da Federação (UF) para investimento na formação de mestres, doutores e atração de pós-doutores; e

II. o monitoramento da evolução do SNPG no atendimento aos temas dessa agenda.

Governança de LLMs



Estratégias emergentes:

1. Model reporting e documentação técnica
2. Avaliação contínua de desempenho e viés
3. Mecanismos de explicação e rastreabilidade

O alicerce da IA confiável

- **Dados** são o insumo primário de qualquer LLM, e sua governança define a **qualidade, legalidade e rastreabilidade** do modelo.
- O cenário atual:
 - Dados dispersos entre edge, nuvem, e ambientes on-premises.
 - Regras regulatórias cada vez mais complexas (LGPD, GDPR, IA Act).
 - Pressão por **democratizar o acesso** sem perder controle.
- Sem uma arquitetura de governança sólida, qualquer sistema de IA é **tecnicamente frágil e juridicamente vulnerável**.

PROBLEMA

NÃO HÁ PADRÃO consolidado para governança de LLMs em ambientes públicos.



Governança de Dados

O que já se conhece de governança de Dados e Analítica



Estrutura de Governança de Dados

Pework: Define Use Cases (EA)

Pré-trabalho: definição de casos de uso, papéis, arquitetura e estratégia de dados.

Estrutura de Governança de Dados

Pework: Define Use Cases (EA)

Descoberta & alinhamento de políticas: identificar fontes e restrições legais.

Step 1

DBA

Data Sources

BA

Profile Data
(Struct./
Unstruct.)

S

Associate Policies

IT Admin, DPO

Onboard Data
(Secure Data
Lake)

EA, E


Apply Policies
(Masking)

Fonte: Gartner

Roles


BA	Business Analyst/Data Analyst	EA	Enterprise Architect
DBA	Database Administrator	S	Data Steward
DPO	Data Protection Officer	DS	Data Scientist
E	Data Engineer (ETL)		

Estrutura de Governança de Dados



Roles			
BA	Business Analyst/Data Analyst	EA	Enterprise Architect
DBA	Database Administrator	S	Data Steward
DPO	Data Protection Officer	DS	Data Scientist
E	Data Engineer (ETL)		

Estrutura de Governança de Dados




Roles			
BA	Business Analyst/Data Analyst	EA	Enterprise Architect
DBA	Database Administrator	S	Data Steward
DPO	Data Protection Officer	DS	Data Scientist
E	Data Engineer (ETL)		

Estrutura de Governança de Dados

Pework: Define Use Cases (EA)

Harmonização & analytics: integração interdepartamental e uso em ML/LLMs.




Roles

BA	Business Analyst/Data Analyst	EA	Enterprise Architect
DBA	Database Administrator	S	Data Steward
DPO	Data Protection Officer	DS	Data Scientist
E	Data Engineer (ETL)		

Estrutura de Governança de Dados

Pework: Define Use Cases (EA)

Operacionalização da governança: monitoramento contínuo, auditoria e melhoria.



Governança de dados em LLMs

- Cada fase da governança tradicional tem um análogo direto em IA
 - **Descoberta de dados:** mapeamento de fontes sensíveis e dados de treino.
 - **Transformação:** anonimização e rotulagem automática (*personally identifiable information - PII*)
 - **Curadoria:** datasets auditáveis e versionados
 - **Operacionalização:** monitoramento de outputs e drifts de modelo.
- **OBJETIVO:** garantir rastreabilidade de ponta a ponta (**DATA LINEAGE**): da coleta ao output do LLM



Governança de IA

garantindo responsabilidade, controle e auditoria em sistemas de IA



As 3 “linhas de frente” da Governança em IA

- Conceito original: **The IIA’s Three Lines Model** *(Institute of Internal Auditors, 2020)*
- **Objetivo:** definir claramente papéis e responsabilidade na governança de IA.

Primeira linha:

Gestão e operação da IA

- Desenvolvedores, cientistas de dados, engenheiros de modelo.
- Responsáveis por aplicar princípios éticos e de compliance no design e uso do modelo.

MANAGEMENT


Actions (including managing risk) to achieve organizational objectives

First line roles:
Provision of products/services to clients; managing risk

Second line roles:
Expertise, support, monitoring and challenge on risk-related matters

As 3 “linhas de frente” da Governança em IA

- Conceito original: **The IIA’s Three Lines Model** *(Institute of Internal Auditors, 2020)*
- **Objetivo:** definir claramente papéis e responsabilidade na governança de IA.




Segunda linha: Controle e conformidade interna

- Comitês de ética, segurança e proteção de dados.
- Monitoram riscos, políticas e aderência a frameworks como LGPD, GDPR, AI Act, ISO 42001, etc.

As 3 “linhas de frente” da Governança em IA

- Conceito original: **The IIA’s Three Lines Model** *(Institute of Internal Auditors, 2020)*
- **Objetivo:** definir claramente papéis e responsabilidade na governança de IA.




As 3 “linhas de frente” da Governança em IA

- Conceito original: **The IIA’s Three Lines Model** (*Institute of Internal Auditors, 2020*)
- **Objetivo:** definir claramente papéis e responsabilidade na governança de IA.

Nível superior: Orgão de Governança

- Estabelece o propósito, valores e cultura ética da instituição.
- Delega autoridade as três linhas e não é considerada uma “quarta linha”.



KEY: ↑ Accountability, reporting ↓ Delegation, direction, resources, oversight ↔ Alignment, communication coordination, collaboration

Papeis e supervisão ética

- Ainda no The IIA's Three Lines Model é possível estabelecer os papéis técnicos, éticos e de auditoria.

Primeira linha:

Criação e execução (Project team)

Responsáveis diretos pela integridade técnica:

- Desenvolvem e operam o modelo (dados, treino, testes, bias check).
- Avaliam riscos associados a cada caso de uso.
- Documentam o processo de desenvolvimento.
- Monitoram desempenho e decaimento do modelo.

Fonte: PwC Analysis



Papeis e supervisão ética


- Ainda no The IIA's Three Lines Model é possível estabelecer os papéis técnicos, éticos e de auditoria.

Segunda linha: Gestão e supervisão (Managers e supervisores)

Asseguram conformidade e aderência às políticas organizacionais:

- Definem padrões e critérios de aceitação.
- Realizam revisões independentes de desempenho e mitigação de riscos.
- Aprovam e acompanham modificações no modelo.

Fonte: PwC Analysis



Papeis e supervisão ética

- Ainda no The IIA's Three Lines Model é possível estabelecer os papéis técnicos, éticos e de auditoria.

Terceira linha: Auditoria e Ética

Garantem independência, transparência e accountability:

- Revisões periódicas de controles e processos.
- Avaliação ética de decisões e alinhamento com valores institucionais

Fonte: PwC Analysis




Papeis e supervis3o 3tica

- Ainda no The IIA's Three Lines Model 3 poss3vel estabelecer os pap3is t3cnicos, 3ticos e de auditoria.

N3vel superior:
Auditoria e 3tica

3RG3OS EXTERNOS: provedores de
garantia e reguladores.

3RG3O DE GOVERNAN3A (CORPO DE
3TICA): supervisiona todo o modelo,
define 3tica e estrat3gia institucional.



Governança de LLMs

*Visão técnica da Governança como componente arquitetural,
não burocrático*

Arquiteturas para governança em LLMs

- Existem 3 opções para construir aplicações de governança com LLMs:
 1. **Treinar do zero:** caro e restrito a organizações com grandes recursos.
 2. **Adaptar modelos abertos pré-treinados:** balanceia custo e controle.
 3. **Consumir APIs hospedadas:** rápido, mas com dependência e riscos de privacidade.

ARQUITETURA MODERNA DE LLMS combina:

1. Dados contextuais (pipelines + embeddings + vetorizações).
2. Orquestração central (controle de prompts, APIs e fluxos).
3. Camadas de validação e logging (governança técnica em tempo real).

LLM App stack

DADOS e o CONTEXTO

- Temos pipelines que capturam dados corporativos e institucionais e os passam por um modelo de embedding, que transforma o conteúdo em representações vetoriais.
- Esses vetores são armazenados em um vector database, que funciona como uma memória semântica: ele permite que, quando uma pergunta é feita ao modelo, possamos recuperar apenas os trechos relevantes, reduzindo custo e melhorando precisão.




LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - ➔ Contextual data provided by app developers to condition LLM outputs
- ➔ Prompts and few-shot examples that are sent to the LLM
- ➔ Queries submitted by users
- ➔ Output returned to users

LLM App stack



PLAYGROUND

- Aqui entram os prompts e few-shot examples, ou seja, exemplos e instruções que ajudam a guiar o comportamento do modelo.

LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed


Arrows show the flow of data through the stack

- - - ➔ Contextual data provided by app developers to condition LLM outputs
- ➔ Prompts and few-shot examples that are sent to the LLM
- ➔ Queries submitted by users
- ➔ Output returned to users

LLM App stack

API/Plugins

- Base do paradigma **RAG (Retrieval-Augmented Generation)**, que une contexto documental e geração de linguagem.
- Permite que a LLM interaja com fontes externas de dados, ferramentas e serviços especializados, tanto para enriquecer o contexto quanto para executar ações após a inferência.
- Ponte de extensão: a LLM deixa de ser apenas um gerador de texto e passa a agir como um agente conectado ao ecossistema institucional.



LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM


==> Queries submitted by users

—> Output returned to users

LLM App stack

ORQUESTRAÇÃO

- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.



LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM


—> Queries submitted by users

—> Output returned to users

LLM App stack

ORQUESTRAÇÃO

- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.
 2. Recupera contexto relevante, buscando nos embeddings ou bases documentais.



LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM


—> Queries submitted by users

—> Output returned to users

LLM App stack

ORQUESTRAÇÃO

- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.
 2. Recupera contexto relevante, buscando nos embeddings ou bases documentais.
 3. Constrói o prompt final, combinando contexto, instruções e histórico.



LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM


—> Queries submitted by users

—> Output returned to users

LLM App stack

ORQUESTRAÇÃO


- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.
 2. Recupera contexto relevante, buscando nos embeddings ou bases documentais.
 3. Constrói o prompt final, combinando contexto, instruções e histórico.
 4. Chama o LLM apropriado que pode estar hospedado localmente, em nuvem aberta ou privada.



LLM App stack

ORQUESTRAÇÃO


- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.
 2. Recupera contexto relevante, buscando nos embeddings ou bases documentais.
 3. Constrói o prompt final, combinando contexto, instruções e histórico.
 4. Chama o LLM apropriado que pode estar hospedado localmente, em nuvem aberta ou privada.
 5. Aplica mecanismos de validação e logging antes e depois da inferência.



LLM App stack

ORQUESTRAÇÃO


- É o sistema que gerencia o fluxo completo de requisições e respostas entre o usuário, os dados, os serviços externos e o LLM.
- Ela não é o modelo em si, mas o “cérebro operacional” que:
 1. Recebe a consulta (query) do usuário ou da aplicação.
 2. Recupera contexto relevante, buscando nos embeddings ou bases documentais.
 3. Constrói o prompt final, combinando contexto, instruções e histórico.
 4. Chama o LLM apropriado que pode estar hospedado localmente, em nuvem aberta ou privada.
 5. Aplica mecanismos de validação e logging antes e depois da inferência.
 6. Retorna a resposta validada à aplicação.



LLM App stack + Governança

PRINCIPIO:

Controlar a saída do modelo não pelo re-treino, mas pelo contexto e pela orquestração.



LLM APIS & hosting

- Base fundamental de linguagem, responsável pela geração propriamente dita de texto

LLM APIs and Hosting



GPT, Claude, Llama, Mistral, etc.

LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM


—> Queries submitted by users

—> Output returned to users

LLM App stack + Governança

PRINCIPIO:

Controlar a saída do modelo não pelo re-treino, mas pelo **contexto** e pela **orquestração**.



LEGEND

Gray boxes show key components of the stack, with leading tools/systems listed

Arrows show the flow of data through the stack

- - - -> Contextual data provided by app developers to condition LLM outputs

—> Prompts and few-shot examples that are sent to the LLM

—> Queries submitted by users

—> Output returned to users



LLMs e Governança no setor Público

Inovação tecnológica e responsabilidade institucional



Motivação

- Governos (órgãos públicos) têm adotado IA para:
 - Tomar decisões mais rápidas, com transparência e eficiência
 - Melhorar políticas públicas baseadas em evidência

Motivação

- Governos (órgãos públicos) têm adotado IA para:
 - Tomar decisões mais rápidas, com transparência e eficiência
 - Melhorar políticas públicas baseadas em evidência
- Quais os principais pontos em comum e desafios?

Motivação

- Governos (órgãos públicos) têm adotado IA para:
 - Tomar decisões mais rápidas, com transparência e eficiência
 - Melhorar políticas públicas baseadas em evidência
- Quais os principais pontos em comum e desafios?
 - Muitos dados textuais (não estruturados)
 - Grandes Modelos de Língua (LLMs)
 - Domínios específicos

LLMs para o setor público

- Desafios de infraestrutura no uso de LLMs

LLMs para o setor público

- Desafios de infraestrutura no uso de LLMs
- Resultados estado-da-arte em muitas tarefas de NLP.
- Requer investimento em infraestrutura (GPUs)
- Alta latência impede aplicações em tempo real e requer tratamento para altos volumes
- Maioria das LLMs requer significativa RAM (vRAM), mesmo para tarefa simples
- Desafiador para ambientes locais ou infraestrutura mais “modestas”
- Desafios de infraestrutura no uso de LLMs
- Privacidade e Transparência.

LLMs para o setor público no Brasil

- Domínio especializado:
 - Muitas tarefas envolvem linguagem técnica, estrutura formal ou nuances regulatórias que não são cobertas no pré-treinamento geral



LLM4Gov: Uma LLM treinada para governança

*um framework de fine-tuning com preservação de
privacidade e governança integrada*



LLM4Gov: A Privacy-Preserving Approach to Teacher-Student Fine-Tuning of Distilled LLMs for the Public Sector

CSBC
45ª EDIÇÃO | MACEIO - AL | 2025



LASDiGov

Latin American Symposium on Digital Government


LLM4Gov

- **OBJETIVO:** Oferecer a instituições interessadas, principalmente do setor público, uma forma de aproveitar o potencial dos LLMs sem violar a privacidade de cidadãos, sem expor dados sensíveis a modelos proprietários externos e sem exigir uma infraestrutura de hardware irrealista para o contexto governamental.
- Pipeline de 3 camadas:
 - **Anonimização:** remoção de informações sensíveis de pessoas físicas e/ou jurídicas.
 - **Modelo “Professor”:** gera instruções, rótulos e explicações.
 - **Modelo “Aluno”:** refinado com LoRA e quantização, rodado em infraestrutura local, responde diretamente ao usuário.

LLM4Gov: visão geral


Step 1 - LLM Teacher

Dataset




LLM4Gov: visão geral

Step 1 - LLM Teacher




LLM4Gov: visão geral

Step 1 - LLM Teacher




LLM4Gov: visão geral

Step 1 - LLM Teacher




LLM4Gov: visão geral

Step 1 - LLM Teacher



LLM4Gov: visão geral

Step 1 - LLM Teacher




João da Silva afirma que foi demitido pela empresa ABC Ltda sem justa causa em 10/03/2023 e, até o momento, não recebeu suas verbas rescisórias.

Rótulo: Direito Trabalhista -
Verbas Rescisórias Não Pagas


```
instrucao : Classifique o tipo de demanda jurídica com base no relato
            apresentado.
input_original_mascarado : [NOME] afirma que foi demitido pela
                           empresa [EMPRESA] sem justa causa em
                           [DATA] e, até o momento, não recebeu suas
                           verbas rescisórias.
input : Um cidadão relata que foi demitido sem justa causa por seu
        empregador e não recebeu as verbas rescisórias devidas.
rotulo : Direito Trabalhista – Verbas Rescisórias Não Pagas
explicacao : A frase '[NOME] afirma que foi demitido [...] sem justa
              causa' indica que se trata de uma rescisão contratual
              imotivada. A continuação 'e, até o momento, não recebeu
              suas verbas rescisórias' caracteriza a violação do
              direito trabalhista ao pagamento no desligamento. Por
              isso, o relato se enquadra na categoria 'Direito
              Trabalhista – Verbas Rescisórias Não Pagas'.
```

LLM4Gov: visão geral

Step 1 - LLM Teacher




Step 2 - LLM Student




LLM4Gov: visão geral

Step 1 - LLM Teacher




Step 2 - LLM Student





LLM4Gov: visão geral

Isso reduz o espaço ocupado em memória em até 8× e aumenta a velocidade de inferência em até 3×, dependendo da arquitetura e do hardware.

Step 1 - LLM Teacher




Step 2 - LLM Student




Normalmente, uma LLM é treinada com pesos de 32 bits (FP32) ou 16 bits (FP16). Na quantização, essa precisão é reduzida para 8 bits, 4 bits ou até menos (INT8, INT4), o que diminui drasticamente o uso de memória e o tempo de inferência.

LLM4Gov: visão geral

Step 1 - LLM Teacher




Step 2 - LLM Student




LLM4Gov: visão geral

Step 1 - LLM Teacher




Step 2 - LLM Student

Labeled Training Dataset



Quantization
Reducing the precision of model weights and activations (FP16 to INT8 or lower)

Parameter-efficient fine-tuning (PEFT) techniques
Low-Rank Adaptation (LoRA)




Esses pesos W são grandes matrizes de projeção usadas em cada camada do Transformer.

Durante o fine-tuning, os pesos originais W são congelados (FREEZE) e o modelo aprende os ajustes necessários ($B \times A$) sem tocar em W .


- Em vez de atualizar bilhões de pesos, o LoRA atualiza apenas alguns milhões (1–2%)
- Como as matrizes A e B têm rank baixo ($r \ll d$), o treinamento pode ser feito com GPUs de 8–16 GB de VRAM
- As matrizes LoRA são arquivos pequenos (~100–300 MB), fáceis de auditar e combinar.

LLM4Gov: visão geral

Step 1 - LLM Teacher



Step 2 - LLM Student



Avaliação experimental: dados

Dataset	Legal Documents
Instâncias (Treino/Teste)	1984 / 851
Tarefa	Classificação de documentos jurídicos
Targets (Chaves JSON)	"category", "resumo", "palavras_chave", "rotulos", "explicacao"

Avaliação experimental: configuração

Modelos comparados	LLM4Gov, LLaMA 3.1 (8B), DeepSeek-R1 (7B)
Configuração de avaliação	Zero-shot, usando os mesmos prompts e dados anonimizados para todos os modelos
Formato de saída esperado	JSON estruturado com múltiplas chaves ("resumo", "palavras_chave", "rotulos", "explicacao", etc.)
Métrica de comparação	BERTScore – avalia similaridade semântica entre a saída dos modelos e a saída do teacher LLM
Objetivo da métrica	Verificar acurácia e proximidade semântica dos modelos em relação ao teacher LLM, mesmo quando há variações de linguagem nas respostas geradas

Avaliação experimental: comparação

Model	Precision (P)	Recall (R)	F1
LLaMA 3.1 (8B)	0.765	0.748	0.756
DeepSeek-R1 (7B)	0.663	0.698	0.680
LLM4Gov (ours)	0.788	0.789	0.788

Avaliação experimental: comparação

Model	Precision (P)	Recall (R)	F1
LLaMA 3.1 (8B)	0.765	0.748	0.756
DeepSeek-R1 (7B)	0.663	0.698	0.680
LLM4Gov (ours)	0.788	0.789	0.788

Approach	Key Idea	Advantages	Limitations
TinyLLM [Tian et al. 2024]	Multi-teacher distillation with Chain-of-Thought reasoning.	Improves student model reasoning and accuracy. Outperforms larger LLMs in certain benchmarks.	Requires multiple LLM teachers, increasing computational cost. Focused on reasoning, not general NLP.
MiniLLM [Gu et al. 2023]	KL divergence optimization for better knowledge transfer.	Enhances response accuracy and calibration. Generalizable across multiple LLM families.	Assumes white-box access to teacher models. No focus on privacy.
LLM4Gov (Proposed)	Teacher-student fine-tuning with anonymized training data for public sector applications.	Domain-specialized model for government tasks. Ensures privacy compliance. Enables efficient deployment in local infrastructures.	Reliance on teacher-generated instructions. Requires further optimization for teacher LLM bias mitigation.

Limitações e trabalhos futuros

- **Mitigação de viés do Teacher**
Investigar formas de reduzir possíveis vieses nos dados gerados pelo modelo Teacher
- **Melhoria da transferência de conhecimento**
LoRA dinâmico por camada
Selective LoRA para fine-tuning
- **Agents4Gov**
Incluir o LLM4Gov como uma *tool* em LLM-based Agent

Obrigado

Prof. Dr. Jorge Valverde-Rebaza

Saiba mais sobre governança:

